Entrega 3 (3ª parcial) — Marco M3

# Modelo de IA avaliado, métricas obtidas e levantamento de custos

| | |
|---|---|
| **Projeto** | Plataforma de Cursos Corporativos (Cursify) |
| **Entregável** | RNF04 / RNF29 / RNF23 — métricas de qualidade e custos de operação |
| **Cards** | #220 (relatório comparativo), #121 (custos de operação) |
| **Data da rodada de medição** | 04/11/2026 |
| **Branch** | feat/220-relatorio-comparativo-deepseek → dev |
| **Autor** | Lucas Senzaki |

**O que este documento prova, com número real:** conformidade de schema, custo por demanda, tokens de entrada/saída e latência p50/p95 — medidos contra a API real do OpenRouter, não estimados. **O que não prova:** qualidade comparativa entre os modelos — o conjunto de avaliação ainda tem só 3 casos sintéticos, sem caso real anotado por humano (ver seção 5). A acurácia automática saiu idêntica entre os três modelos por essa razão, não porque eles tenham qualidade igual.

**Nota sobre o termo "modelo treinado":** este projeto não treina nem ajusta pesos de modelo de linguagem — usa modelos de terceiros (OpenRouter) por engenharia de prompt e barreira de schema. "Modelo", neste documento, é o modelo de LLM escolhido e configurado para a tarefa de estruturação, não um modelo treinado do zero ou ajustado (fine-tuned).

# 1. Contexto e objetivo

Este documento consolida o entregável de métricas de qualidade e custos de operação da 3ª parcial: qual modelo de linguagem o pipeline de estruturação de cursos usa, as métricas reais obtidas por ele na tarefa do projeto, e o levantamento de custo de operação.

Reúne duas fontes de dado, nunca misturadas sem identificação clara:

1. **Preço catalogado** dos quatro modelos candidatos originais do projeto (Sonnet 4.5, GPT-4o mini, Gemini 2.5 Flash, Llama 3.3 70B) — consultado direto na API pública do OpenRouter, sem chamada de estruturação nova nesta rodada.
2. **Medição real**, nesta rodada, de três modelos da família DeepSeek entre si — a disputa interna que este relatório resolve antes de levar DeepSeek à disputa entre fornecedores: vale pagar mais pelo raciocínio em cadeia (R1) dentro da própria família, ou o nível mais barato (V4.1 Flash) já entrega o que o produto precisa?

O critério cobrado pela banca — trade-off entre qualidade, custo e latência, explicitado e reproduzível — é respondido na seção 4 para a disputa interna; a seção 3 declara as condições exatas para que outra pessoa repita a medição.

# 2. Modelo de IA avaliado

O pipeline de estruturação (`ai-structuring-service`) chama um modelo de linguagem configurável via variável de ambiente (`LLM_PROVIDER`/`LLM_MODEL`), através do OpenRouter como agregador de provedores. Nesta rodada, três candidatos da família DeepSeek foram avaliados entre si:

| Modelo | Slug (OpenRouter) | Característica | Preço USD/Mtok (entr./s |
|---|---|---|---|
| DeepSeek R1 | deepseek/deepseek-r1-0528 | Raciocínio em cadeia (reasoning) | 0,50 / 2,15 |
| DeepSeek Chat V3.1 | deepseek/deepseek-chat-v3.1 | Padrão, sem reasoning | 0,25 / 0,95 |
| DeepSeek V4.1 Flash | deepseek/deepseek-v4.1-flash | Nível mais barato do catálogo | 0,045 / 0,50 |

Preço consultado direto na API pública do OpenRouter (`openrouter.ai/api/v1/models`) em 04/11/2026, registrado com data e fonte em `app/evaluation/modelos.toml` — nunca preço estimado ou copiado de agregador terceiro.

# 3. Condições de execução (reprodutibilidade)

| Condição | Valor |
|---|---|
| Data da rodada | 04/11/2026 |
| Provedor | OpenRouter — API real (chave de teste já rotacionada) |
| Versão do prompt | extract-requirements.v6 |
| Parâmetros fixos | temperature=0, timeout=90s, max_retries=2, schema_max_retries=2 |
| Caso de uso medido | StructuringService.structure_course — o mesmo da rota POST /api/v1/structuring |
| Conjunto de avaliação | 3 casos sintéticos — 0 casos reais anonimizados |
| Execuções | 3 modelos × 3 casos × 1 repetição = 9 chamadas reais |

| Condição | Valor |
|---|---|
| Saída bruta (fonte das métricas) | docs/04-ia/avaliacoes/dados/2026-11-04-v6.json |

**Defeito de produção encontrado e corrigido durante esta rodada.** `app/evaluation/runner.py` reusava o mesmo objeto de configuração para todos os modelos da rodada; como o modelo pedido ao provedor vinha desse objeto compartilhado e nunca era sobrescrito por candidato, **toda chamada contra um provedor HTTP real pedia sempre o mesmo modelo**, não importa qual o catálogo indicasse — mascarado até hoje porque o provedor de testes (mock) ignora esse campo. Esta foi a primeira rodada deste projeto com múltiplos modelos reais no mesmo lote contra um provedor HTTP, e por isso a primeira a expor o defeito. Corrigido com uma cópia de configuração por modelo dentro do laço de execução; confirmado pelo provedor devolvendo o modelo correto nas 9 execuções desta rodada (antes da correção, 6 das 9 chamadas foram servidas pelo modelo errado). Suíte completa do serviço (359 testes) permanece verde após a correção.

# 4. Métricas obtidas

## 4.1 Custo, tokens e latência (medição real)

| Modelo | Tok. entrada (méd.) | Tok. saída (méd.) | Latência p50 | Latência p95 | Custo/ demanda | Conform. schema |
|---|---|---|---|---|---|---|
| DeepSeek R1 | 7 064 | 2 027 | 45,5 s | 147,3 s | $0,007890 | 100% |
| DeepSeek Chat V3.1 | 7 063 | 289 | 11,6 s | 12,8 s | $0,002041 | 100% |
| DeepSeek V4.1 Flash | 7 089 | 3 158 | 8,6 s | 25,0 s | $0,001898 | 100% |

## 4.2 Qualidade automática da estruturação

| Modelo | Casos | Acurácia | Essenc. | Cobert. | Alucin. | Ausênc. | Schema | Falha | Evidência | Citação inválida |
|---|---|---|---|---|---|---|---|---|---|---|
| DeepSeek R1 | 3 | 33% | 100% | 45% | 0% | 25% | 100% | 0% | 100% | 0% |
| DeepSeek Chat V3.1 | 3 | 33% | 100% | 45% | 0% | 25% | 100% | 0% | 100% | 0% |
| DeepSeek V4.1 Flash | 3 | 33% | 100% | 45% | 0% | 25% | 100% | 0% | 100% | 0% |

As métricas de qualidade saíram **idênticas entre os três modelos**. Com apenas 3 casos sintéticos, essa igualdade não diz que os modelos têm a mesma qualidade — diz que o conjunto atual não tem variação suficiente para diferenciá-los nessas métricas. A diferenciação real desta rodada está em custo e latência, não em qualidade automática, e fica assim até o conjunto ter os 20 casos reais anotados que a 3ª parcial pede (ver seção 5).

## 4.3 Leitura dos números

**R1 é o único com raciocínio em cadeia**, e isso custa caro nos dois eixos que importam para este produto: 4–6× mais tokens de saída que os outros dois, e latência p95 de quase 2,5 minutos — muito acima do alvo de 15 s (RNF06). Para uma extração estruturada com schema fixo, que não pede argumentação em várias etapas, o raciocínio extra não tem onde se gastar de forma útil.

**V4.1 Flash, apesar do nome, não foi o mais econômico em tokens** — produziu mais tokens de saída em média que o Chat V3.1 (3 158 vs. 289) e teve a cauda de latência mais instável (8,6 s a 25 s). Ainda assim ficou mais barato por demanda porque seu preço por token de saída é uma fração do dos outros dois. Como o modelo suporta parâmetros de `reasoning`, parte dessa saída maior pode ser raciocínio implícito não solicitado — não investigado nesta rodada, fica como item de acompanhamento antes de adotar o modelo em produção.

**Chat V3.1 é o mais previsível**: saída enxuta e de baixa variância entre casos, latência estável (11,6 a 13,0 s, a menor variação dos três) e custo intermediário.

## 5. Recomendação e justificativa do trade-off

**Modelo recomendado para a disputa interna DeepSeek:** `deepseek/deepseek-chat-v3.1`**.**

Não é o mais barato por demanda nesta amostra pequena ($0,002041 contra $0,001898 do V4.1 Flash) — mas a diferença é de $0,000143 por demanda, irrelevante no volume do cliente (seção 6), enquanto a previsibilidade de latência e de tamanho de saída do Chat V3.1 pesa mais para um produto com alvo de resposta em até 15 s (RNF06).

**R1 fica descartado** para este fluxo: o custo de raciocínio em cadeia não se paga numa extração com schema fixo, e sua latência p95 viola o alvo de tempo por uma margem grande. **V4.1 Flash permanece candidato de reserva** para cenários em que custo marginal importa mais que previsibilidade de latência, condicionado a investigar a saída maior que a observada no Chat V3.1.

**Frente aos quatro candidatos originais do catálogo** (preço, não medição nova nesta rodada): o Chat V3.1 ($0,25/$0,95 por Mtok) fica abaixo do GPT-4o mini, e muito abaixo do Sonnet 4.5 ($3,00/$15,00) e do Gemini 2.5 Flash ($0,30/$2,50) no preço de saída — o lado mais caro desta tarefa, já que a saída inclui o JSON estruturado inteiro. Uma rodada de qualidade cruzando DeepSeek Chat V3.1 contra os quatro candidatos originais, no mesmo conjunto, é o próximo passo natural, e só vira número reportável quando o conjunto tiver os casos reais anotados.

## 6. Levantamento de custos

Custo medido cobre hoje só a chamada de extração (`structure_course`); o passo de geração de ementa (RF12) ainda não existe como chamada separada (`generate-syllabus.v1` continua rascunho) — o custo real de produção, quando esse passo existir, será maior que o medido aqui.

| Grandeza | DeepSeek R1 | DeepSeek Chat V3.1 | DeepSeek V4.1 Flash |
|---|---|---|---|
| Tokens de entrada / demanda (méd.) | 7 064 | 7 063 | 7 089 |
| Tokens de saída / demanda (méd.) | 2 027 | 289 | 3 158 |
| Custo por demanda (USD) | $0,007890 | $0,002041 | $0,001898 |
| Latência p50 / p95 | 45,5 s / 147,3 s | 11,6 s / 12,8 s | 8,6 s / 25,0 s |
| Custo mensal projetado* | $0,35 a $0,52 | $0,09 a $0,13 | $0,08 a $0,13 |

* Projeção para 2–3 demandas/dia × 22 dias úteis = 44–66 demandas/mês, no volume declarado do cliente real.

No volume do cliente, o custo mensal de API para qualquer um dos três candidatos DeepSeek fica **abaixo de US$ 0,60/mês** — confortavelmente dentro da premissa de operação em camada gratuita/estudantil (RNF23/RNF12). O modelo recomendado (Chat V3.1) projeta US$ 0,09 a US$ 0,13/mês.

## 7. Limitações desta rodada

O conjunto de avaliação não tem caso real anotado por humano (bloqueado por falta de dado real anonimizado do cliente, card #18). As métricas de qualidade desta rodada validam que o arnês de avaliação funciona — não são medição reportável da qualidade do produto perante o cliente. Para a próxima rodada, o conjunto precisa dos 20 casos reais anotados que a 3ª parcial pede, e nessa rodada o DeepSeek Chat V3.1 recomendado aqui deve ser comparado diretamente contra os quatro candidatos originais do catálogo, não só entre si.

O custo medido cobre apenas uma chamada por demanda (extração); a segunda chamada prevista no desenho original do produto (geração de ementa, RF12) ainda não existe, então o custo real de produção

será maior que o projetado na seção 6 quando esse passo for implementado.

## 8. Rastreabilidade

| Artefato | Caminho |
|---|---|
| Relatório comparativo completo | `docs/04-ia/avaliacoes/relatorio-comparativo-modelos.md` |
| Levantamento de custos | `docs/04-ia/custos-operacao.md` |
| Relatório automático da rodada | `docs/04-ia/avaliacoes/2026-11-04-v6.md` |
| Dados brutos das 9 execuções | `docs/04-ia/avaliacoes/dados/2026-11-04-v6.json` |
| Catálogo de modelos e preços | `services/ai-structuring-service/app/evaluation/modelos.toml` |
| Correção de bug aplicada | `services/ai-structuring-service/app/evaluation/runner.py` |
| Matriz de rastreabilidade | `docs/01-requisitos/matriz-rastreabilidade.md (RNF04, RNF23)` |
| Pull request | `#293 — feat/220-relatorio-comparativo-deepseek → dev` |